

# Entrega 1 Estadística

Guillem Tutusaus i Alcaraz, 1533701

03/04/2024

1. Sigui  $x = (x_1, \dots, x_n)$ ,  $n > 2$  observacions independents, idènticament distribuïdes amb funció de probabilitat

$$\mathbb{P}(X_i = x_i) = p(1-p)^{x_i-1}$$

on  $x_i \in \mathbb{N}$ ,  $p \in (0, 1)$ .

- (a) Calculem el valor esperat de  $S_n(X) := \sum_{i=1}^n X_i$ .

$$\mathbb{E}(S_n(X)) = \mathbb{E}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \mathbb{E}(X_i) = n\mathbb{E}(X_1)$$

on en aquesta darrera igualtat hem fet servir que  $X_1, \dots, X_n$  son idènticament distribuïdes. Ara,

$$\mathbb{E}(X_1) = \sum_{i \geq 1} ip(1-p)^{i-1} = p \frac{1}{p^2}$$

per tant,  $\mathbb{E}(X_1) = \frac{1}{p}$ . D'aquesta manera,

$$\mathbb{E}(S_n(X)) = \frac{n}{p}$$

També podríem haver observat que  $X_1 \sim \text{Geom}(p)$  que sabem que si aquesta té suport  $\mathbb{N}$ , aleshores  $\mathbb{E}(X_1) = \frac{1}{p}$ .

- (b) Trobem un estadístic suficient per  $p$ .

Un estadístic  $T$  és suficient per un paràmetre  $\theta$  si la probabilitat condicionada de la nostra mostra, donat  $T$  no depèn del paràmetre. En el nostre cas, el paràmetre és  $p$ . Escrivint la probabilitat condicionada tenim

$$\frac{\mathbb{P}(X_1 = x_1, \dots, X_n = x_n | T = t)}{\mathbb{P}(T = t)} =$$

pel teorema de Bayes.

Notem que, al ser les  $X_i$ 's independent idènticament distribuïdes podem escriure el següent

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n \mathbb{P}(X_i = x_i) = \prod_{i=1}^n p(1-p)^{x_i-1}$$

A més, si  $X_i \sim \text{Geom}(p)$  per a tot  $i$ , aleshores considerant  $S_n(X) := \sum_{i=1}^n X_i$  és fàcil veure per inducció sobre  $n$  que  $S_n \sim NB(n, p)$ . D'aquesta manera, considerant l'estadístic  $S_n(X) := \sum_{i=1}^n X_i$  tenim

$$\mathbb{P}(S_n = t) = \binom{t-1}{n-1} p^n (1-p)^{t-n}$$

on  $t \in \{n, n+1, \dots\}$ . Per últim, observem que

$$\mathbb{P}(S_n = t | X_1 = x_1, \dots, X_n = x_n) = \begin{cases} 1 & \text{si } t = \sum_{i=1}^n x_i \\ 0 & \text{altrament} \end{cases}$$

Per tant,

$$\begin{aligned} \mathbb{P}(X_1 = x_1, \dots, X_n = x_n | S_n = t) &= \frac{\prod_{i=1}^n p(1-p)^{x_i-1}}{\binom{t-1}{n-1} p^n (1-p)^{t-n}} \\ &= \frac{p^n (1-p)^{\sum_{i=1}^n x_i - n}}{\binom{t-1}{n-1} p^n (1-p)^{t-n}} = \frac{(1-p)^{\sum_{i=1}^n x_i}}{\binom{t-1}{n-1} (1-p)^t} = \frac{1}{\binom{t-1}{n-1}} \end{aligned}$$

com estem suposant que  $t = \sum_{i=1}^n x_i$  obtenim el resultat  $\frac{1}{\binom{t-1}{n-1}}$  que no depèn de  $p$  i per tant això demostra que  $S_n(X)$  és un estadístic suficient per  $p$ .

(c) Trobem un estimador no esbiaixat per  $\frac{1}{p}$  en termes de  $S_n(X)$ .

Per (1a) sabem que  $\mathbb{E}(S_n(X)) = \frac{n}{p}$ , per tant considerant

$$T_n(X) := \frac{1}{n} S_n(X)$$

ja ho hauriem de tenir. Comprovem-ho,

$$\mathbb{E}(T_n(X)) = \frac{1}{n} \mathbb{E}(S_n(X)) = \frac{1}{n} \frac{n}{p} = \frac{1}{p}$$

com volíem veure. En particular, l'estimador buscat és

$$T_n(x) = \frac{1}{n} \sum_{i=1}^n x_i$$

(d) Trobem un estimador no esbiaixat per  $p$  en termes de  $S_n(X)$ .

Recordem que si  $X$  és una variable aleatòria discreta i  $h : \mathbb{R} \rightarrow \mathbb{R}$  una funció tal que

$$\sum_{k \in S} |h(k)| \mathbb{P}(X = k) < \infty$$

aleshores definim l'esperança de  $h(X)$  com

$$\mathbb{E}(h(X)) = \sum_{k \in S} h(k) \mathbb{P}(X = k)$$

Ara, tenint present la indicació donada considerem l'estadístic

$$Q_n(X) := \frac{1}{S_n(X) - 1}$$

i en calculem la seva esperança. Per això cal recordar que  $S_n \sim NB(n, p)$  té funció de probabilitat  $\mathbb{P}(S_n = k) = \binom{k-1}{n-1} p^n (1-p)^{k-n}$ ,  $k \in \{n, n+1, \dots\}$ . D'aquesta manera,

$$\begin{aligned} \mathbb{E}(Q_n) &= \mathbb{E}\left(\frac{1}{S_n - 1}\right) \\ &= \sum_{k \geq n} \frac{1}{k-1} \mathbb{P}(S_n = k) \\ &= \sum_{k \geq n} \frac{1}{k-1} \binom{k-1}{n-1} p^n (1-p)^{k-n} \\ &= \frac{1}{(n-1)!} \left(\frac{p}{1-p}\right)^n \sum_{k \geq n} \frac{(k-1)!}{(k-1)(k-n)!} (1-p)^k \\ &= \frac{1}{(n-1)!} p^n \sum_{i \geq 0} \frac{(i+n-2)!}{i!} (1-p)^i \\ &= \frac{1}{(n-1)!} p^n \frac{(n-2)!}{p^{n-1}} \\ &= \frac{p}{n-1} \end{aligned}$$

D'aquesta manera i en virtut de les observacions fetes anteriorment, tenim que l'estimador

$$(n-1)Q_n(x)$$

verifica el que volem. Per completitud calculem la sèrie

$$\sum_{i \geq 0} \frac{(i+n-2)!}{i!} (1-p)^i$$

Comencem reescriuint el numerador com

$$\frac{(i+n-2)!}{i!} = (i+1)(i+2)\dots(i+n-2)$$

Agafant ara la sèrie de potències  $f(x) = \sum_{i \geq 0} x^i = \frac{1}{1-x}$  per  $|x| < 1$  i prenent-ne la  $(n-2)$ -derivada veiem

$$f^{(n-2)}(x) = \sum_{i \geq n-2} i(i-1)\dots(i-n+3)x^{i-(n-2)} = \frac{(n-2)!}{(1-x)^{n-1}}$$

Així doncs la nostra sèrie és

$$\sum_{i \geq 0} \frac{(i+n-2)!}{i!} (1-p)^i = f^{(n-2)}(1-p) = \frac{(n-2)!}{p^{n-1}}$$

2. Una mostra  $X_1, \dots, X_n$  s'extreu d'una distribució normal  $N(\theta, \theta^2)$ .

(a) Troba un interval de confiança del 90% per la mitjana poblacional  $\theta$ .

Per calcular un interval de confiança del 90% per  $\theta$  considerem el següent estimador.

$$\frac{\bar{X} - \theta}{\frac{S_X}{\sqrt{n}}}$$

Sabem de teoria que aquest estimador té distribució t-Student amb  $n-1$  graus de llibertat, i.e.

$$\frac{\bar{X} - \theta}{\frac{S_X}{\sqrt{n}}} \sim t^{n-1}$$

Això ens permet construir un interval de confiança per  $\theta$ . Un interval de confiança del 90% ( $\alpha = 0.1$ ) per a la distribució  $t^{n-1}$  és

$$(t_{0.05}^{n-1}, t_{0.95}^{n-1}) = (-t_{0.95}^{n-1}, t_{0.95}^{n-1})$$

on  $t_{0.95}^{n-1}$  és el quantil 95% de la distribució amb  $n-1$  graus de llibertat. D'aquesta manera, podem construir un interval per  $\theta$

$$\begin{aligned} -t_{0.95}^{n-1} &< \frac{\bar{X} - \theta}{\frac{S_X}{\sqrt{n}}} < t_{0.95}^{n-1} \\ -t_{0.95}^{n-1} \frac{S_X}{\sqrt{n}} &< \bar{X} - \theta < t_{0.95}^{n-1} \frac{S_X}{\sqrt{n}} \\ \bar{X} - t_{0.95}^{n-1} \frac{S_X}{\sqrt{n}} &< \theta < \bar{X} + t_{0.95}^{n-1} \frac{S_X}{\sqrt{n}} \end{aligned}$$

- (b) Volem fer un test per determinar si existeix un canvi respecte la mitjana poblacional i un conjunt de dades anteriorment obtinguda. Quina mida de la mostra necessitem per detectar un canvi de 0.1 amb una significació del 95% i una potència del 90% si sabem que  $\bar{X} = 12$ ?

Per tal de respondre a aquesta pregunta ens plantejem el següent test per a  $\theta$  amb variància desconeguda.

$$\begin{cases} H_0 : \theta - \theta_0 = 0 \\ H_1 : |\theta - \theta_0| \geq 0.1 \end{cases}$$

On  $\theta_0$  representa la mitjana poblacional del primer test realitzat. Notem que al disposar de tan poques hipòtesis, al fer les dues observacions, obtindrem  $\hat{X}, \hat{X}_0, S_X^2$  i  $S_{X_0}^2$ .

Ara, sabem pel Seminari 3 que sota les condicions anteriors

$$\frac{(\hat{X} - \hat{X}_0) - (\theta - \theta_0)}{\sqrt{\frac{S_X^2}{n_X} + \frac{S_{X_0}^2}{n_{X_0}}}} \sim t^k$$

on no estem suposant que coneguem les variancies de les dues mitjanes ni que siguin la mateixa ni tampoc que les mides de les mostres siguin iguals (per això  $n_X$  i  $n_{X_0}$ ). Aquest estadístic segueix una llei  $t^k$  amb  $k$  graus de llibertat. Per trobar els graus de llibertat en aquest cas cal resoldre:

$$k = \frac{\left(\frac{S_X^2}{n_X} + \frac{S_{X_0}^2}{n_{X_0}}\right)^2}{\frac{\left(\frac{S_X^2}{n_X}\right)^2}{n_X - 1} + \frac{\left(\frac{S_{X_0}^2}{n_{X_0}}\right)^2}{n_{X_0} - 1}}$$

Sabem per hipòtesis que  $\mathbb{P}(\text{Acceptar } H_1 | H_0 \text{ certa}) = \alpha = 0.05$ , és a dir, per rebutjar la hipòtesis nul·la sapiguent que és certa, s'ha de complir que

$$\left| \frac{12 - \hat{X}_0}{\sqrt{\frac{S_X^2}{n_X} + \frac{S_{X_0}^2}{n_{X_0}}}} \right| > |t_{1-\frac{\alpha}{2}}^k|$$

que en ambdues inequacions ens dona

$$n_X > \frac{(t_{1-\frac{\alpha}{2}}^k \theta_0)^2 n_{X_0}}{(12 - \hat{X}_0)^2}$$

Per altra banda, tenim que  $\mathbb{P}(\text{Acceptar } H_0 | H_1 \text{ certa}) = \beta = 0.1$ . Per calcular la mida necessària per a que es compleixi aquest succés,

suposem que  $H_1 : |\theta - \theta_0| = 0.1$ , per resoldre un cas senzill. Aleshores, el nostre estadístic quedaria així:

$$\frac{12 - \hat{X}_0 - 0.1}{\sqrt{\frac{S_X^2}{n_X} + \frac{S_{X_0}^2}{n_{X_0}}}}$$

Per tant, per a acceptar la hipòtesis nul·la sapiguent que  $H_1$  és certa, s'ha de complir que

$$\left| \frac{12 - \hat{X}_0 - 0.1}{\sqrt{\frac{S_X^2}{n_X} + \frac{S_{X_0}^2}{n_{X_0}}}} \right| < |t_{1-\frac{\alpha}{2}}^k|$$

Això passa si

$$n_X < \frac{(t_{1-\frac{\alpha}{2}}^k)^2 (\theta_0^2 + 0.2\theta_0 + 0.01) n_{X_0}}{(11.9 - \hat{X}_0)^2}$$

Aleshores tindrem:

$$\left\{ \begin{array}{l} n > \frac{(t_{1-\frac{\alpha}{2}}^k \theta_0)^2 n_{X_0}}{(12 - \hat{X}_0)^2} \\ n < \frac{(t_{1-\frac{\alpha}{2}}^k)^2 (\theta_0^2 + 0.2\theta_0 + 0.01) n_{X_0}}{(11.9 - \hat{X}_0)^2} \end{array} \right.$$

El cas  $\theta - \theta_0 = -0.1$  és similar.